

2.th Chunking, Embedding, OpenSearch: Store&Search

www.youtube.com/@HONGJOONG-SHIN theprismdata@gmail.com

1. Chunking

목적 Large Lange Model이 받아 들일 수 있는 크기의 문자(토큰)로 긴 문장을 조각 작은 토큰으로 잘라내면서, 상용 LLM의 비용 절약 효과

오는 25일부터 30일까지 설 연휴 기간 데이터 통신 ...데이터 도매대가를 낮출 예정이다. 또 중고폰의 안전한 거래 환경 조성을 위한 중고폰 안심거래 사업자 인증제도를 추진한다.

....

오는 25일부터 30일까지 설 연휴 기간.

데이터 통신 요금 부담 없이 영상통 화가 무료로 제공된다



1. Chunking

종류 RecursiveCharacterTextSplitter

separators (["₩n₩n", "₩n", " ", ""])를 기준으로 문장을 분할

chunk_size : 글자를 설정된 길이를 넘지 않도록 분할

chunk_overlap : 분할 된 문장에서 이전 문장에 포함할 글자 수

chunk overlap을 사용할 경우 검색시 문맥 단절 현상 방지

온 가족이 함께 과학문화를 즐길 수 있도록 설 연휴기간 동안 중앙(대전), 과천, 광주, 부산 등 소관 국립과학관 5곳의 상설전시관을 무료로 개방한다. 각 과학관에서 을사년 뱀관련 별자리 해설, 민속놀이 등

질문

답변 마지막

온 가족이 함께 **과학문화를 즐길 수 있도록 설 연휴기간** 동안 중앙(대전), 과천, 광주, 부산 등 소관 국립과학관 5곳의 창설전시관을 무료로 개방한다. 각 **과학관에서 을사년**

을사년 뱀관련 발자리 해설, 민속놀이 등 다양한 과학문화 전시와 체험행사를 즐길 수 있다.

추가 내용

1. Chunking

종류 NLTKTextSplitter

NLTK의 문장 토크 나이저를 사용하여 문장 단위로 텍스트 분할

chunk_size : 최대 길이를 넘지 않도록 함

chunk_overlap: 분할 된 문장에서 이전 문장에 포함할 글자 수

chunk overlap을 사용할 경우 검색시 문맥 단절 현상 방지

온 가족이 함께 과학문화를 즐길 수 있도록 설 연휴기간 동안 중앙(대전), 과천, 광주, 부산 등 소관 국립과학관 5곳의 상설전시관을 무료로 개방한다. 각 과학관에서 을사년 뱀관련 별자리 해설, 민속놀이 등

고물가 시대 국민의 가계통신비 부담을 완화하고 소비자 후생을 향상하기 위해 발표된 알뜰폰 경쟁력 강화방안에 따라 데이터 도매대가를 낮출 예정이다. 또 중고폰의 안전한 거래 환경 조성을 위한 중고폰 안심거래 사업자인증제도를 추진한다.

또 중고폰의 안전한 거래 환경 조성을 위한 중고폰 안심거래 사업자 인증제도를 추진한다. 설 장바구니 물가 부담을 낮출 수 있도록 오는 30일까지 '2025년 우체국쇼핑 설 선물대전'을 진행한다.

2. Embedding

목적 사람이 쓰는 자연어를 컴퓨터가 이해할 수 있는 숫자의 나열인 Vector(행렬)로 바꿈

2025.01.20. 오후 12:01

https://n.news.naver.com/article/092/0002360502?cds=news_media_pc&type=editn

[오는 25일부터 30일까지 설 연휴 기간 데이터 통신 요금 부담 없이 영상통화가 무료로 제공된다.]

```
[-3.04232180e-01 -6.26503825e-01 -4.61999416e-01 -4.66390222e-01 -1.56113058e-01 2.99530268e-01 -6.98186040e-01 -1.18409050e+00 1.00436628e+00 4.64943588e-01 -9.49845433e-01 4.15850103e-01
```

••••

```
2.33040616e-01 -3.78922403e-01 1.32098496e-01 -9.12056491e-02 -2.00412273e-01 6.72386527e-01 1.11323878e-01 -8.46709847e-01 -1.10680744e-01 -1.24335192e-01 -8.31869721e-01 -1.72620559e+00 3.48826170e-01 -3.57889205e-01 3.85624588e-01 9.57825303e-01]
```

임베딩 모델 KR-SBERT-V40K-klueNLI-augSTS

목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 1 OpenSearch Docker 설치 windows cmd에서 초기 암호 설정 (admin의 암호가 복잡해야 설치됩니다.) set OPENSEARCH_INITIAL_ADMIN_PASSWORD=juntPass123!

컨테이너 Restart시 데이터 유지를 위해 볼륨 설정 (docker/docker-compose.yml 에서 찾음)

 \sim \sim

volumes:

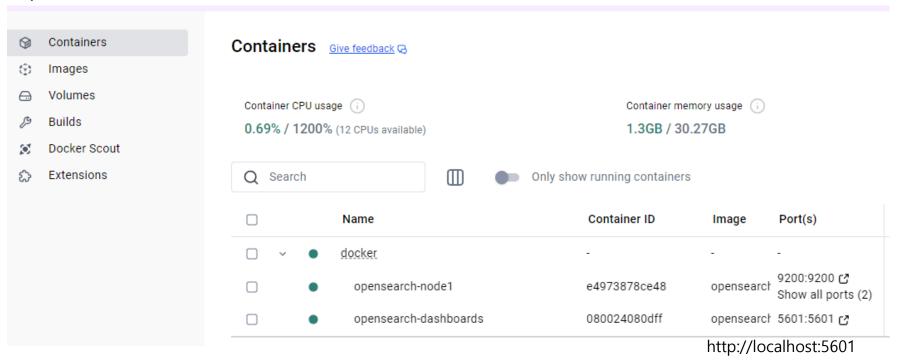
- /c/Temp/opensearch:/usr/share/opensearch/data

c:\Temp\opensearch 폴더가 생성됩니다.

docker 컨테이너 실행 docker-compose -f docker\docker-compose.yml up

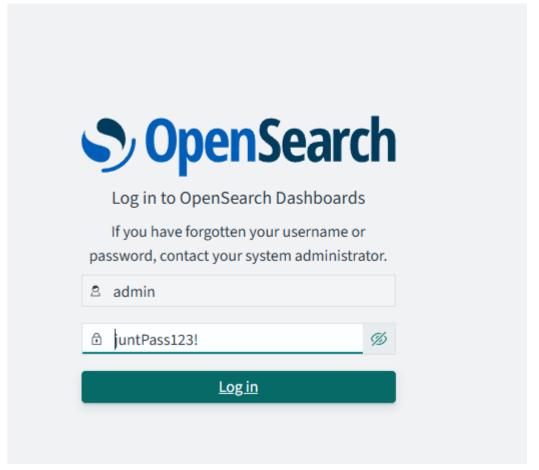
목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 1 OpenSearch Dashboard 컨테이너 접속



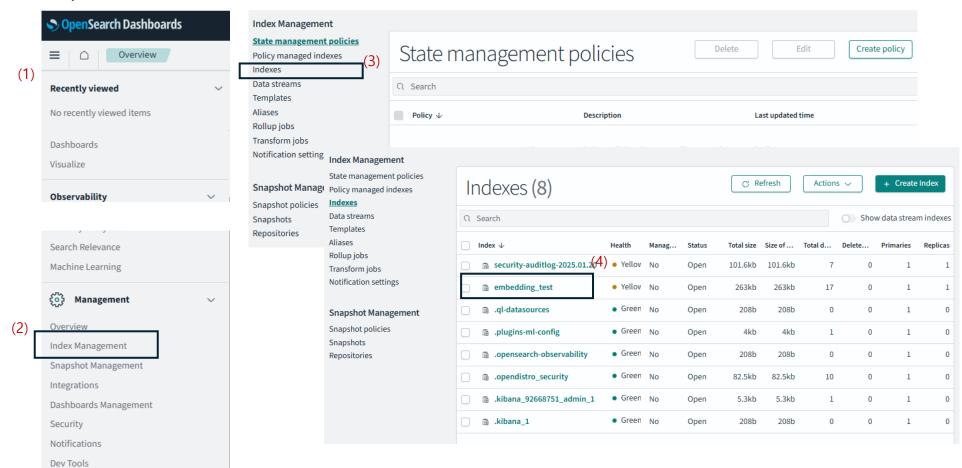
목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 1 OpenSearch Dashboard 로그인



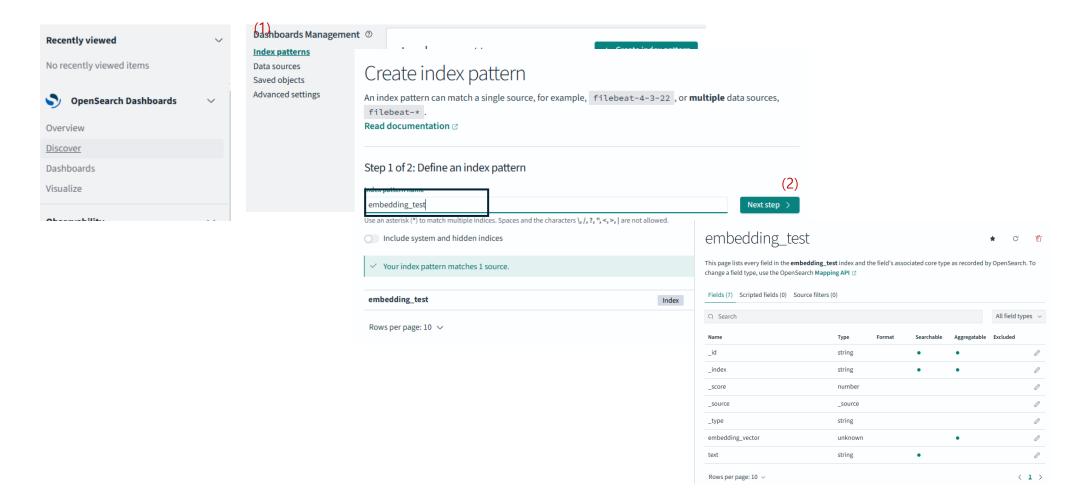
목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 2 OpenSearch 생성된 Index 확인



목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 3 OpenSearch Index pattern (embedding_test) 등록



목적 문자열, 단어 검색이 아닌 유사한 Vector를 검색하기 위해 사용

Stage 4 OpenSearch Index (embedding_test)의 vector와 저장된 데이터 보기

